

## 5. MEDIDAS ESTATÍSTICAS

### 5.1. Introdução

No tópico anterior foi visto a síntese (ou resumo) de séries de dados sob a forma de apresentações tabulares, apresentações gráficas e as distribuições de frequências.

Trata-se agora dos cálculos das medidas que possibilitam apresentar e confrontar séries de dados, relativas às observações dos fenômenos, de forma sintética e resumida.

### 5.2. Medidas de tendência central

Tais medidas orientam quanto aos valores centrais.

Representam os fenômenos pelos seus valores médios, em torno dos quais tendem a se concentrar os dados.

#### 5.2.1. Média aritmética

Medida de tendência central de uso mais comum.

Notação adotada: ( $\bar{Y}$  ou  $\mu$ ) para o parâmetro e ( $\bar{y}$  ou  $m$ ) para a estimativa.

##### 5.2.1.1. Dados não agrupados

Sejam  $y_1, y_2, \dots, y_n$ , portanto ( $N, n$ ) valores da variável  $Y$ . A média aritmética simples de  $Y$  representada por ( $\bar{Y}, \bar{y}$ ) é definida por:

$$\text{Parâmetro: } \bar{Y} \text{ ou } \mu = \frac{\sum y}{N}$$

$$\text{Estimativa: } \bar{y} \text{ ou } m = \frac{\sum y}{n}$$

Exemplo: considerando {3, 7, 8, 10, 11} como uma amostra:

$$\bar{y} = \frac{3+7+8+10+11}{5} = 7,8$$

##### 5.2.1.2. Dados agrupados

Quando os dados de uma amostra estiverem agrupados numa distribuição de frequência a média aritmética dos valores de  $Y$  ( $y_1, y_2, \dots, y_n$ ), ponderados pelas respectivas frequências absolutas:  $F_1, F_2, \dots, F_n$  é calculada como se segue:

$$\bar{y} \text{ ou } m = \frac{\sum y \cdot F}{\sum F}$$

### Exemplos:

Y	F <sub>i</sub>	YF <sub>i</sub>
1	1	1
2	3	6
3	5	15
4	1	4
Σ	10	26

$$\bar{y} \text{ ou } m = \frac{\sum y \cdot F}{\sum F} = \frac{26}{10} = 2,6$$

Idade	F <sub>i</sub>	Y	YF <sub>i</sub>
02 + 04	5	3	15
04 + 06	10	5	50
06 + 08	14	7	98
08 + 10	8	9	72
10 + 12	3	11	33
Σ	40		268

As classes são representadas pelos seus pontos médios:

$$\bar{y} \text{ ou } m = \frac{\sum y \cdot F}{\sum F} = \frac{268}{40} = 6,7$$

##### 5.2.1.3. Média geral

Sejam  $\bar{y}_1, \bar{y}_2, \dots, \bar{y}_k$  as estimativas das médias aritméticas de  $K$  séries e  $n_1, n_2, \dots, n_k$  os números de termos destas séries, respectivamente. A média aritmética da série formada pelos termos da  $K$  séries é dada pela fórmula:

$$\bar{y} \text{ ou } m = \frac{n_1 \bar{y}_1 + n_2 \bar{y}_2 + \dots + n_k \bar{y}_k}{n_1 + n_2 + \dots + n_k}$$

Exemplo: Sejam as séries:

$$1) \{4, 5, 6, 7, 8\} \quad \text{em que} \quad n_1 = 5 \quad \text{e} \quad \bar{y}_1 = 6$$

$$2) \{1, 2, 3\} \quad \text{em que} \quad n_2 = 3 \quad \text{e} \quad \bar{y}_2 = 2$$

$$3) \{9, 10, 11, 12, 13\} \quad \text{em que} \quad n_3 = 5 \quad \text{e} \quad \bar{y}_3 = 11$$

$$\bar{Y} = \frac{n_1 \bar{y}_1 + n_2 \bar{y}_2 + \dots + n_k \bar{y}_k}{n_1 + n_2 + \dots + n_k} = \frac{5 \cdot 6 + 3 \cdot 2 + 5 \cdot 11}{5 + 3 + 5} = 7$$

### 5.2.2. Média geométrica

Usada para médias proporcionais de crescimento quando uma medida subsequente depende de medidas prévias.

Notação adotada: (MG) para o parâmetro e (mg) para a estimativa.

Sejam  $y_1, y_2, \dots, y_n$ , valores de Y associados às respectivas freqüências absolutas  $F_1, F_2, \dots, F_n$ . A média geométrica (MG ou mg) de Y é definida por:

$$MG \text{ ou } mg = \sqrt[n]{y_1^{F_1} \cdot y_2^{F_2} \cdot \dots \cdot y_n^{F_n}}$$

Exemplo:

Média geométrica de uma amostra {3, 6, 12, 24, 48}

$$mg = \sqrt[5]{3 \cdot 6 \cdot 12 \cdot 24 \cdot 48} = \sqrt[5]{248.832} = 12$$

### 5.2.3. Média harmônica

Usada para médias de crescimento e proporções de velocidade.

Notação adotada: (MH) para o parâmetro e (mh) para a estimativa.

Sejam  $y_1, y_2, \dots, y_n$ , valores de Y, associados às respectivas freqüências absolutas  $F_1, F_2, \dots, F_n$ . A média harmônica (MH ou mh) de Y é definida por:

$$MH \text{ ou } mh = \frac{n}{\frac{F_1}{y_1} + \frac{F_2}{y_2} + \dots + \frac{F_n}{y_n}} = \frac{n}{\sum_{i=1}^n \frac{F_i}{y_i}}$$


Exemplo:

Média harmônica de uma amostra {2, 5, 8}

$$mh = \frac{3}{\frac{1}{2} + \frac{1}{5} + \frac{1}{8}} = 3,64$$

### 5.2.4. Mediana

Medida de tendência muito usada quando o interesse é a determinação do valor que separa a série de dados em duas partes iguais, 50% situados acima e 50% situados abaixo da medida.



Notação adotada: ( $\tilde{Y}$  ou MD) para o parâmetro e ( $\tilde{y}$  ou mg) para a estimativa.

Colocados em ordem crescente, a mediana ( $\tilde{Y}$ ,  $\tilde{y}$ ) é o valor que divide a série em duas partes iguais:

#### 5.2.4.1. Cálculo da mediana para variável discreta

Se n for ímpar, a mediana será o elemento central (de ordem  $\frac{n+1}{2}$ ).

Caso n seja par, a mediana será a média entre os elementos centrais (de ordem  $\frac{n}{2}$  e  $\frac{n}{2} + 1$ ).

Exemplo 1:

$Y_i$	$F_i$	$F_{ac}$
1	1	1
2	3	4
3	5	9
4	2	11
$\Sigma$	11	

← contém o 6º elemento

$n = 11$ , n é ímpar, logo  $\tilde{y}$  será o elemento de ordem  $\frac{n+1}{2}$ , ou seja  $\frac{11+1}{2} = 6^\circ$

Será, portanto, o sexto elemento.

Por meio das freqüências acumuladas encontra-se o valor  $y_i$  correspondente a mediana, que neste exemplo é 3 ( $\tilde{y} = 3$ ).

Exemplo 2:

$Y_i$	$F_i$	$F_{ac}$
82	5	5
85	10	15
87	15	30
89	8	38
90	4	42
$\Sigma$	42	

← contém os 21º e 22º elementos

$n = 42$ , n é par, logo  $\tilde{y}$  será a média entre os elementos de ordem  $\frac{n}{2}$  e  $\frac{n}{2} + 1$

Ou seja  $\frac{42}{2} = 21$  e  $\frac{42}{2} + 1 = 22$  (21º e 22º elementos)

Identificam-se os elementos de ordem 21º e 22º pela  $F_{ac}$

Assim, o 21º corresponde a 87 e 22º corresponde a 87, logo:

$$\tilde{y} = \frac{87 + 87}{2} = 87$$

### 5.2.4.2. Cálculo da mediana para variável contínua

1º passo: calcula-se a ordem  $\frac{n}{2}$ . Como a variável é contínua, não importa se n é par ou impar.

2º passo: pela  $F_{ac}$  identifica-se a classe que contém a mediana (classe md).

3º passo: usa-se fórmula:

$$\tilde{y} = \ell_{md} + \frac{\left(\frac{n}{2} - \sum f\right) \cdot h}{F_{md}}$$

Em que:

$\ell_{md}$  = limite inferior da classe md

n = tamanho da série

$\sum f$  = soma das freqüências anteriores à classe md

h = amplitude da classe md

$F_{md}$  = freqüência da classe md

Exemplo:

Classe	$F_i$	$F_{ac}$	
35 - 45	5	5	
45 - 55	12	17	
55 - 65	18	35	← classe mediana
65 - 75	14	49	
75 - 85	6	55	
85 - 95	3	58	
$\Sigma$	58	268	

1º passo:  $\frac{58}{2} = 29$

2º passo: classe md = 3ª

3º passo: usa-se a fórmula:

$\ell_{md} = 55$ ;  $n = 58$ ;  $\sum f = 17$ ;  $h = 10$ ;  $F_{md} = 18$

$$\tilde{y} = 55 + \frac{\left(\frac{58}{2} - 17\right) \cdot 10}{18} = 61,67$$

### 5.2.5. Moda

Medida de tendência central muito usada quando o interesse é o valor mais freqüente da série.

Notação adotada: (MO) para o parâmetro e (mo) para a estimativa.

A moda pode não existir – o que constitui uma série amodal – ou, mesmo que exista pode não ser única – o que caracteriza uma série multimodal.

Para distribuições simples (sem agrupamento de classes), a identificação da moda é facilitada pela simples observação do elemento que apresenta maior freqüência.

Assim, considerando a distribuição abaixo como uma amostra:

$y_i$	243	245	248	251	307
$F_i$	7	17	23	20	8

A moda será 248, e indica-se por  $mo = 248$ .

#### 5.2.5.1. Moda para dados agrupados em classes

1º passo: identifica-se a classe modal (maior freqüência).

2º passo: usa-se a fórmula de Czuber

$$mo = \ell + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot h$$

Em que:

$\ell$  = limite inferior da classe mo

$\Delta_1$  = diferença entre a freqüência da classe modal e a imediatamente anterior

$\Delta_2$  = diferença entre a freqüência da classe modal e a imediatamente posterior

h = amplitude da classe

Exemplo:

Classes	0 - 1	1 - 2	2 - 3	3 - 4	4 - 5	$\Sigma$
$F_i$	3	10	17	8	5	43

1º passo: indica-se a classe modal: 3ª (2 - 3)

2º passo: usa-se a fórmula

$$mo = \ell + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot h$$

$$mo = 2 + \frac{7}{7+9} \cdot 1 = 2,44$$

### 5.3. Comparação entre as medidas de tendência central

#### 5.3.1. Média

##### 5.3.1.1. Vantagens

- Fácil de compreender e calcular
- Utiliza todos os valores da série
- É um valor único
- É fácil de ser incluída em expressões matemáticas
- Pode ser determinada nas escalas: intervalar e proporcional.

##### 5.3.1.2. Desvantagens

- Muito afetada por valores extremos
- Necessário conhecer todos os valores da série.

#### 5.3.2. Mediana

##### 5.3.2.1. Vantagens

- Fácil de compreender e aplicar
- Não é afetada por valores extremos
- É um valor único
- É fácil de incluir em expressões matemáticas
- Pode ser determinada nas escalas: ordinal, intervalar e proporcional.

##### 5.3.2.2. Desvantagens

- É difícil de ser incluída em expressões matemáticas
- Não usa todos os valores da série.

#### 5.3.3. Moda

##### 5.3.3.1. Vantagens

- Fácil de compreender e calcular
- Não é afetada por valores extremos
- Pode ser aplicada em todas as escalas: nominal, ordinal, intervalar e proporcional.

##### 5.3.3.2. Desvantagens

- Pode estar afastada do centro dos valores
- É difícil de ser incluída em expressões matemáticas
- Não usa todos os valores da série
- A variável pode ter mais de uma moda (bimodal ou multimodal)
- Algumas variáveis não possuem moda.


### 5.4. Medidas de posição ou separatrizes

Genericamente denominadas quantis, orientam quanto à posição na distribuição.

Permitem determinar valores que particionam a série de n observações em partes iguais.

#### 5.4.1. Quartis

Seguindo o mesmo raciocínio da mediana, os três quartis dividem uma série em 4 partes iguais:



Notação adotada: (Q) para o parâmetro e (q) para a estimativa.

$$q_i = \ell_{q_i} + \frac{\left(\frac{i \cdot n}{4} - \sum f\right) \cdot h}{F_{q_i}}$$

Em que:

$\ell_{q_i}$  = limite inferior da classe  $q_i$  ( $i = 1, \dots, 3$ )

$i$  = 1 para  $q_1$ , ..., 3 para  $q_3$

$n$  = tamanho da série


$\sum f$  = soma das frequências anteriores à classe  $q_i$

$h$  = amplitude da classe  $q_i$

$F_{q_i}$  = frequência da classe  $q_i$

#### 5.4.2. Decis

Os decis dividem a série em 10 partes iguais.



Notação adotada: (D) para o parâmetro e (d) para a estimativa.

$$d_i = \ell_{d_i} + \frac{\left(\frac{i \cdot n}{10} - \sum f\right) \cdot h}{F_{d_i}}$$

Em que:

$\ell_{d_i}$  = limite inferior da classe  $d_i$  ( $i = 1, \dots, 9$ )

$i$  = 1 para  $d_1$ , ..., 9 para  $d_9$

$n$  = tamanho da série


$\sum f$  = soma das freqüências anteriores à classe  $d_i$

$h$  = amplitude da classe  $d_i$

$F_{d_i}$  = freqüência da classe  $d_i$

#### 5.4.3. Percentis

Os percentis (P para populações e p para amostras) dividem a série em 100 partes iguais.



Notação adotada: (P) para o parâmetro e (p) para a estimativa.

$$p_i = \ell_{p_i} + \frac{\left(\frac{i \cdot n}{100} - \sum f\right) \cdot h}{F_{p_i}}$$

Em que:

$\ell_{p_i}$  = limite inferior da classe  $p_i$  ( $i = 1, \dots, 99$ )

$i$  = 1 para  $p_1$ , ..., 99 para  $p_{99}$

$n$  = tamanho da série

$\sum f$  = soma das freqüências anteriores à classe  $p_i$

$h$  = amplitude da classe  $p_i$

$F_{p_i}$  = freqüência da classe  $p_i$

Os procedimentos para determinar os quartis, decis e percentis são semelhantes aos usados para determinar o valor da mediana.

#### 5.4.4. Situações de uso mais comuns destas medidas

Uma dos usos mais comuns, e importantes, destas medidas na análise exploratória dos dados é o diagrama de caixa ("box plot"), como abaixo:




Figura 5.1 – Diagrama de caixa do total de fêmeas do parasitóide nascidas.